


GAP: Yapay Zekâ Servisleri Entegrasyon Şeması (AI_SCHEMA)

Bu belge; Nebius Serverless üzerinde çalışan FastAPI orkestratörünün **Groq Cloud (Whisper STT & TTS)** ve **Nebius Token Factory (NVIDIA Nemotron LLM)** ile olan doğrudan iletişimini, API uç noktalarını, parametrelerini, prompt yapısını ve `ai/schema.json` uyumunu eksiksiz olarak tanımlar.

1. Mimari Şema



2. Bileşen Sorumlulukları

Bileşen	Sorumluluk / Ne Yapar?
ESP32 (Donanım)	- I2S mikrofon ile sesi 16 kHz Mono WAV formatında kaydeder ve FastAPI'ye gönderir. - FastAPI'den dönen sentezlenmiş ses verisini hoparlörden çalar. - Cihaz test telemetrisi (ping) ve buton basış durumlarını (outcome) iletir.
Nebius Serverless (FastAPI)	- Sistemin tek iletişim ve orkestrasyon merkezidir. - Bearer token ile donanım kimlik doğrulamasını yapar. - Groq (STT/TTS), Nemotron ve Supabase API çağrılarını sırayla yönetir. - Uyum yüzdesi ve gecikme gibi matematiksel hesaplamaları yürütür (Stateless).
Groq Cloud	- Whisper Large V3 ile gelen sesi minimum gecikmeyle metne çevirir (STT). - FastAPI'nin ilettiği onay/cevap metnini doğrudan alınabilir sese dönüştürür (TTS).
Nemotron API	- Transkript metnini ayrıştırarak JSON şemasına uygun plan verisi (başlık, tarih, saat, kategori) üretir. - Kullanıcı geçmişine göre proaktif öneri metinleri oluşturur.
Supabase	Kullanıcılar (users), oluşturulan planlar (plans) ve gerçekleşen eylemler (outcomes) için PostgreSQL kalıcı depolamasıdır.

3. Yapay Zekâ Servisleri Entegrasyon Sözleşmesi

FastAPI sunucusu, yapay zekâ işlevleri için iki harici sağlayıcıyı OpenAI uyumlu REST API protokolü üzerinden tüketir:

- Groq Cloud:** STT (Konuşma -> Metin) ve TTS (Metin -> Konuşma)
- Nebius Token Factory:** NVIDIA Nemotron LLM (Plan Çıkarımı & Öneri Üretimi)

```
[ESP32 Ses (WAV)]
  -> FastAPI
  -> 1. Groq STT (Whisper) -> Transkript Metni
  -> 2. Nebius Token Factory (Nemotron) -> ParsedPlan (JSON)
  -> Supabase Kaydı
  -> 3. Groq TTS -> Sentezlenmiş Ses (WAV)
  -> FastAPI
  -> [ESP32 Hoparlör (WAV)]
```

3.1. Groq Cloud: Speech-to-Text (STT) - Whisper Large V3

Groq LPU (Language Processing Unit) altyapısı sayesinde Whisper modelleri 100-300 ms gibi ultra düşük gecikmeyle çalışır. ESP32'den gelen 16 kHz mono WAV sesi doğrudan bu uç noktaya yönlendirilir.

- **API Uç Noktası:** POST `https://api.groq.com/openai/v1/audio/transcriptions`
- **Yetkilendirme:** Authorization: Bearer `$GROQ_API_KEY`
- **İçerik Tipi:** `multipart/form-data`

İstek Parametreleri (Form-Data)

Parametre	Tip	Zorunlu	Değer / Açıklama
<code>file</code>	Binary	Evet	ESP32'den gelen 16 kHz, 16-bit Mono WAV ses dosyası (azami 10 sn / ~320 KB).
<code>model</code>	String	Evet	<code>whisper-large-v3</code> (veya <code>whisper-large-v3-turbo</code>). Yüksek doğruluk ve Türkçe dil desteği için <code>whisper-large-v3</code> önerilir.
<code>language</code>	String	Hayır	<code>"tr"</code> (Modelin dil tahmin adımını atlayıp gecikmeyi düşürmek ve Türkçe doğruluğunu artırmak için sabitlenir).
<code>response_format</code>	String	Hayır	<code>"json"</code> (Varsayılan) veya <code>"verbose_json"</code> .
<code>temperature</code>	Float	Hayır	<code>0.0</code> (Halüsinasyonu engellemek ve deterministik transkript almak için).

Örnek İstek (HTTP / cURL)

```
POST /openai/v1/audio/transcriptions HTTP/1.1
Host: api.groq.com
Authorization: Bearer gsk_...
Content-Type: multipart/form-data; boundary=----WebKitFormBoundary

-----WebKitFormBoundary
Content-Disposition: form-data; name="model"

whisper-large-v3
-----WebKitFormBoundary
Content-Disposition: form-data; name="language"

tr
-----WebKitFormBoundary
Content-Disposition: form-data; name="temperature"

0.0
-----WebKitFormBoundary
Content-Disposition: form-data; name="file"; filename="audio.wav"
Content-Type: audio/wav

<binary audio bytes>
-----WebKitFormBoundary--
```

Başarılı Yanıt (HTTP 200 OK)

```
{
  "text": "Yarın saat 18:00'de spor salonuna gideceğim."
}
```

3.2. Nebius Token Factory: NVIDIA Nemotron LLM (Plan Çıkarımı)

Nebius Token Factory, NVIDIA'nın geliřmiř açık kaynaklı **Nemotron** model ailesini sunar. Model, OpenAI uyumlu `/chat/completions` arayüzü ve JSON modu ile çağrılır. Üretilen çıktının projedeki **ai/schema.json** (**ParsedPlan**) sözleşmesine harfiyen uyması şarttır.

- **API Uç Noktası:** POST `https://api.studio.nebius.ai/v1/chat/completions` (veya `.env` içinde tanımlanan `$NEBIUS_BASE_URL/chat/completions`)
- **Yetkilendirme:** Authorization: Bearer `$NEBIUS_API_KEY`
- **İçerik Tipi:** `application/json`
- **Kullanılan Model:** `.env.example` içinde tanımlı modeller:
 - `MODEL_ULTRA`: `nvidia/Llama-3_1-Nemotron-Ultra-253B-v1` (veya `nvidia/Llama-3_1-Nemotron-70B-Instruct-HF`)
 - `MODEL_NANO`: `nvidia/nemotron-mini-4b-instruct` (hızlı sınıflandırmalar için)

İstek Gövdesi (JSON Payload)

Alan	Tip	Değer
model	String	"nvidia/Llama-3_1-Nemotron-Ultra-253B-v1"
temperature	Float	0.1 (Kural tabanlı JSON doğruluğu için çok düşük sıcaklık)
response_format	Object	{"type": "json_object"}
messages	Array	system (Sistem promptu + ai/schema.json kuralları) ve user (Transkript + Güncel Tarih + Saat Dilimi)

Sistem Promptu ve İstek Örneği

```
{
  "model": "nvidia/Llama-3_1-Nemotron-Ultra-253B-v1",
  "temperature": 0.1,
  "response_format": { "type": "json_object" },
  "messages": [
    {
      "role": "system",
      "content": "Sen GAP asistanının niyet ve plan ayrıştırma motorusun. Kullanıcının konuşma transkriptini a"
    },
    {
      "role": "user",
      "content": "Güncel Tarih: 2026-10-09\nSaat Dilimi: Europe/Istanbul\nTranskript: \"Yarın saat 18:00'de sp"
    }
  ]
}
```

Başarılı Model Yanıtı (ai/schema.json Uyumlu)

```
{
  "id": "chatcmpl-nebius-92184",
  "object": "chat.completion",
  "created": 1791544800,
  "model": "nvidia/Llama-3_1-Nemotron-Ultra-253B-v1",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "{\n  \"intent\": \"create_plan\",\n  \"title\": \"Spor salonu\",\n  \"category\": \"sport\"
      },
      "finish_reason": "stop"
    }
  ]
}
```

FastAPI gelen `choices[0].message.content` dizgesini Pydantic ile doğrular. Doğrulama başarısız olursa model bir kez daha uyarılır veya `422 validation_error` üretilir.

3.3. Groq Cloud: Text-to-Speech (TTS) - Ses Sentezi

FastAPI, oluşturulan planın onayını veya kullanıcıya iletilecek geri bildirimi sesli mesaja dönüştürmek için Groq Audio Speech uç noktasını kullanır.

- **API Uç Noktası:** POST `https://api.groq.com/openai/v1/audio/speech`
- **Yetkilendirme:** `Authorization: Bearer $GROQ_API_KEY`
- **İçerik Tipi:** `application/json`

İstek Parametreleri (JSON Payload)

Parametre	Tip	Zorunlu	Değer / Açıklama
<code>model</code>	String	Evet	<code>canopylabs/orpheus-v1-english</code> veya Groq üzerindeki aktif TTS model kimliği (örn. PlayAI Dialog).
<code>input</code>	String	Evet	Cihazın seslendireceği geri bildirim metni (Örn: "Yarın saat 18:00 için spor salonu planınız kaydedildi.").
<code>voice</code>	String	Evet	Ses karakteri / persona kimliği (Örn: "autumn", "troy", "diana").
<code>response_format</code>	String	Hayır	"wav" (Varsayılan ve zorunlu: ESP32 ek bir MP3 dekodere ihtiyaç duymadan ham PCM/WAV formatını doğrudan I2S üzerinden hoparlöre basabilir).

Örnek İstek (JSON)

```
{
  "model": "canopylabs/orpheus-v1-english",
  "input": "Planınız başarıyla kaydedildi. Yarın akşam 18:00'de spor salonu.",
  "voice": "autumn",
  "response_format": "wav"
}
```

Başarılı Yanıt (HTTP 200 OK)

- `Content-Type: audio/wav`
- `Body` : Binary WAV ses verisi (ESP32'ye doğrudan stream edilir).

3.4. Dayanıklılık, Hata Yönetimi ve Zaman Aşımı (Timeouts & Retries)

Uçtan uca ses döngüsünün 1.5 saniyenin altında tamamlanması için FastAPI seviyesinde aşağıdaki kurallar uygulanır:

- Zaman Aşımı (Timeout) Kriterleri:**
 - **Groq STT:** Azami 3.0 saniye. Aşılırsa -> `504 Gateway Timeout` ("Ses yazıya çevrilemedi").
 - **Nemotron LLM:** Azami 4.0 saniye. Aşılırsa -> `504 Gateway Timeout` ("Plan çıkarımı zaman aşımına uğradı").
 - **Groq TTS:** Azami 3.0 saniye. Aşılırsa -> Yanıt ses olmadan yalnızca HTTP header'daki metinle döner (fallback).
- Pydantic Şema Doğrulaması:**
 - Nemotron'dan dönen JSON `ai/schema.json` dosyasındaki zorunlu alanları içermezse, FastAPI modeli bir kez daha zorlar. İkinci denemede de uymuyorsa `502 parse_failed` üretilir ve veritabanına bozuk veri yazılmaz.
- Deterministik Matematik Ayrımı:**
 - Uyum yüzdesi, gecikme süresi ve gün bazlı istatistikler **asla Nemotron'a hesaplatılmaz**. Matematiksel hesaplamalar FastAPI analiz motorunda Python ile yapılır; Nemotron yalnızca çıkan sayılara insani bir öneri cümlesi yazar.